

Reporte Final: Modelado de Precios de Alojamiento (Rio de Janeiro)

Ian V. Connon-Garzía

Facultad de Ingeniería

Universidad Austral

Pilar, Argentina

ivconnongarzia@mail.austral.edu.ar

Franco T. Esterellas-Engler

Facultad de Ingeniería

Universidad Austral

Pilar, Argentina

festerellas@mail.austral.edu.ar

Tomás M. Saldías

Facultad de Ingeniería

Universidad Austral

Pilar, Argentina

tsaldias@mail.austral.edu.ar

Abstract—Este proyecto tiene como objetivo predecir el precio por noche por persona (`price_by_night_person`) de alojamientos en Rio de Janeiro. Para ello, se ha desarrollado un pipeline de Machine Learning escalable e interpretable que permite al negocio entender los factores que impulsan el precio, utilizando datos enriquecidos (características del hotel, amenities, ubicación, estacionalidad, etc.). Al mismo tiempo, se probaron diversas estrategias de modelado, iterando sobre distintas lógicas de agrupamiento, particionamiento de datos y técnicas avanzadas de ensamble.

I. RESUMEN EJECUTIVO

Este proyecto tiene como objetivo predecir el precio por noche por persona (`price_by_night_person`) de alojamientos en Rio de Janeiro. Para ello, se ha desarrollado un pipeline de Machine Learning escalable e interpretable que permite al negocio entender los factores que impulsan el precio, utilizando datos enriquecidos (características del hotel, amenities, ubicación, estacionalidad, etc.).

Al mismo tiempo, probamos diversas estrategias de modelado, iterando sobre distintas lógicas de agrupamiento, particionamiento de datos y técnicas avanzadas de ensamble.

II. FEATURE ENGINEERING

El procesamiento de los datos fue estructurado en tres pilares para capturar de forma robusta las dinámicas espaciales, temporales y comerciales del mercado hotelero de Rio de Janeiro. Además, se implementaron banderas booleanas (`is_missing`) para cada variable imputada, permitiendo al modelo aprender de la propia ausencia de información (ej. cuando un hotel no reporta sus estrellas o ratings).

A. Ingeniería Temporal y de Eventos

El tratamiento del tiempo fue más allá de la simple extracción de fechas, incorporando la naturaleza cíclica del turismo:

- **Transformaciones Cíclicas:** Se calculó el día de la semana del check-in y se transformó utilizando funciones trigonométricas (seno y coseno) para que el modelo entienda la proximidad continua entre el domingo y el lunes (eliminando el salto artificial entre extremos).
- **Etiquetado de Eventos (Event Flags):** Se construyeron variables booleanas explícitas para capturar picos anómalos de demanda, específicamente Carnaval (2024 y 2025), Rock in Rio 2024 y Réveillon 2024. Esto proporciona un

ancla determinista para explicar los outliers de precios temporales.

Nota Crítica: Las fechas de los eventos están codificadas de forma fija (hardcodeadas). Para ingestar datos de 2026 en adelante, estas variables requerirán la integración de una API de calendario dinámico.

B. Geometría Espacial Estática (Fase A)

El espacio fue tratado con rigor trigonométrico, proyectando las coordenadas originales al sistema UTM Zona 23S (EPSG:32723) para medir distancias métricas reales, evitando la distorsión del sistema WGS84:

- **Densidad Kernel (KDE):** Se calculó un mapa de calor topográfico sobre la concentración de hoteles, asignando a cada propiedad un valor de densidad espacial (aunque con potencial colinealidad con la costa, dado que la infraestructura carioca se aglomera en las playas).
- **Distancias a Nodos de Interés:** Se extrajeron distancias euclidianas exactas hacia aeropuertos (GIG, SDU), estaciones de metro, la línea de costa (playas) y el Cristo Redentor utilizando datos de OpenStreetMap.
- **Contexto Socioeconómico:** Se midió la distancia a la favela más cercana, incorporando métricas de tamaño, densidad por hectárea y vulnerabilidad de salud. Un excelente proxy para la percepción de exclusividad o seguridad.

C. Procesamiento Inductivo y Prevención de Leakage (Fase B)

La arquitectura implementa un muro de contención estricto para evitar que la información de validación o prueba contamine el aprendizaje:

- **Partición Train/Validation/Test:** Se definió un conjunto de Test completamente aislado (“Caja Fuerte”) para evaluar la arquitectura final. Internamente, la separación Train/Validation se hizo agrupando por `searchid` (sesión de búsqueda), asegurando que los hoteles vistos en una misma consulta no se repartan entre ambos sets.
- **Imputación Condicional y Banderas `is_missing`:** Los valores nulos en ratings y habitaciones se rellenaron

utilizando la media agrupada por `starRating`, calculadas exclusivamente sobre el entrenamiento. Fundamentalmente, para cada variable imputada se creó una bandera booleana (`is_missing`), permitiendo al algoritmo aprender de la propia ausencia de datos.

- **Análisis de Correspondencias Múltiples (MCA):** Se aplicó sobre las amenities para extraer 8 dimensiones latentes. El espacio matricial se entrenó solo en validación/entrenamiento y se proyectó correctamente sin fuga.
- **Métricas de Vecindario (k-NN):** Distancias promedio a los 5, 10 y 20 vecinos más cercanos dentro del conjunto de entrenamiento. Se eliminó explícitamente del vector el precio promedio de dichos vecinos para forzar al modelo a comprender el valor intrínseco de la geografía y evitar una profecía autocumplida (“copiado”).

III. EVOLUCIÓN ARQUITECTÓNICA (STACKING DINÁMICO)

El proyecto evolucionó hacia un diseño que fusiona enfoques de segmentación espacial con algoritmos robustos a colas pesadas: el Cuadrante Mágico de Stacking.

A. Enrutamiento Rígido Orientado al Target (Hard Routing)

Implementamos un Enrutador (`DecisionTreeRegressor`) supervisado por el Target (Precio). A diferencia de un clustering no supervisado (K-Means), el Árbol segmenta el espacio intentando predecir el precio utilizando las siguientes variables:

- **Dimensiones Latentes de Amenities (`mca_dim`):** Para agrupar propiedades con servicios y lujos similares.
- **Geometría Espacial (`dist_`):** Para capturar el efecto del barrio, distancias a playas y puntos de interés.
- **Calidad y Tamaño (`Rating` y `numberOfRooms`):** Para distinguir entre grandes cadenas corporativas, alojamientos informales y hoteles boutique VIP.
- **Selección de Clústeres:** Al entrenarse contra el Target, el árbol determina empíricamente divisiones puras. Decidimos podarlo en 6 Hojas (clústeres), ya que fue la configuración matemáticamente más efectiva para aislar los regímenes de precios en Rio de Janeiro.

B. Expertos Locales y Globales (Capa 1)

Dentro de cada una de las 6 hojas del enrutador, se entrenaron especialistas locales calibrando hiperparámetros con Optimización Bayesiana (Optuna):

- **Expertos Tweedie Locales (XGBoost y LightGBM):** Optimizados con la función de pérdida Tweedie (Varianza 1.5) para soportar la enorme volatilidad sin penalizar asimétricamente a la cola larga.
- **Experto MAE Local (LightGBM):** Un modelo calibrado estrictamente para minimizar el Error Absoluto Medio, actuando como un “francotirador” en el rango central de precios de cada hoja.
- **Experto Global (LightGBM Tweedie):** A la par de los expertos de hoja, se entrenó un modelo global unificado

sobre todo el dataset. Su función es proveerle a la Capa 2 un marco de referencia general (“baseline”) para anclar las predicciones en caso de que los expertos locales sufran inestabilidad por bajo volumen en alguna hoja particular.

C. Meta-Modelos de Decisión (Capa 2)

Se utilizaron dos jueces lineales para ponderar las predicciones base:

- **Ridge Regression:** Su fuerte penalización L2 castiga duramente la varianza extrema (el “Escudo de Varianza”).
- **Huber Regressor:** Combina MSE para errores pequeños y MAE para grandes. Ignora a los hoteles millonarios y optimiza el error en dólares.

IV. RESULTADOS FINALES: LOS GANADORES VS. BASELINE

Para dimensionar el valor aportado por esta compleja arquitectura, se entrenó inicialmente un modelo de **Regresión Lineal Simple (Ridge Global)** asumiendo un comportamiento unificado para toda la ciudad. Sus resultados empíricos fueron un **MAE de \$50.94 USD** y un R^2 de **0.1250**.

La evaluación de nuestra arquitectura final sobre el 100% de los datos reales, demostró una superioridad abrumadora frente al baseline, determinando a los siguientes campeones empíricos:

1) Ganador en Varianza (Tweedie Puro + Ridge):

- $R^2 = 0.6766$ $MAE = 22.87$ USD
- *Uso:* Reportes financieros agregados y Revenue Management macro.

2) Ganador en Precisión (Tweedie & MAE + Huber):

- $MAE = 19.42$ USD $R^2 = 0.6131$
- *Uso:* Despliegue en Front-End para predicción hiper-precisa al usuario final.

V. EL IMPACTO DE ELIMINAR OUTLIERS (EXPERIMENTO CONDICIONADO)

Se puso a prueba la metodología tradicional de eliminar del dataset los outliers extremos (Hoteles > 1000 USD y < 10 USD). Al entrenar a nuestra arquitectura ganadora sobre este dataset truncado, las métricas experimentaron una mejora espectacular y artificial:

- **Tweedie+MAE + Huber:** El MAE bajó a un récord de **16.23 USD**.
- **Tweedie+MAE + Ridge Condicional:** El R^2 alcanzó un asombroso **0.7171**.

Conclusión: Limpiar outliers produce métricas artificialmente superiores que ganan competencias, pero fallan en producción. Para un entorno real donde el inventario VIP debe tarificarse correctamente, los modelos oficiales siguen siendo los entrenados sobre el 100% de la varianza.

VI. PRÓXIMOS PASOS E INVESTIGACIONES FUTURAS

- **Explicabilidad (SHAP):** Queda pendiente la ejecución del cálculo de valores SHAP para auditar las decisiones a nivel individual. Dado el diseño de Stacking actual, esto requerirá ejecutar e interpretar los SHAP values de manera local y duplicada para cada uno de los 6 clústeres.
- **Análisis Profundo de Clústeres:** Analizar a nivel comercial el contenido exacto de los 6 clústeres generados por el enrutador espacial, determinando qué tipos de hoteles, amenities o franjas geográficas capturó naturalmente el árbol de decisión.